

Házi feladat bemutatás

Sigmoid Squad


Armand Szokoly	<i>(VN450W)</i>
Balázs Kiss	<i>(NXG36N)</i>
Lőrinc Toldi	<i>(DORAU5)</i>

Bevezetés, célkitűzések, motiváció

- hajók automatikus detektálása műholdképeken
- tengeri megfigyelés, logisztika, biztonság
- különböző szegmentációs megközelítések összehasonlítása
- valós, nagy méretű ipari adatbázison való tapasztalatszerzés

Airbus Ship Detection Challenge

Find ships on satellite images as quickly as possible



[Overview](#) [Data](#) [Code](#) [Models](#) [Discussion](#) [Leaderboard](#) [Rules](#)

Dataset Description

In this competition, you are required to locate ships in images, and put an aligned bounding box segment around the ships you locate. Many images do not contain ships, and those that do may contain multiple ships. Ships within and across images may differ in size (sometimes significantly) and be located in open sea, at docks, marinas, etc.

For this metric, object segments cannot overlap. There were a small percentage of images in both the Train and Test set that had slight overlap of object segments when ships were directly next to each other. Any segments overlaps were removed by setting them to background (i.e., non-ship) encoding. Therefore, some images have a ground truth may be an aligned bounding box with some pixels removed from an edge of the segment. These small adjustments will have a minimal impact on scoring, since the scoring evaluates over increasing overlap thresholds.

The `train_ship_segmentations.csv` file provides the ground truth (in run-length encoding format) for the training images. The `sample_submission` files contains the images in the `test` images.

Files

208164 files

Size

31.41 GB

Type

jpg, csv

License

[Subject to Competition Rules](#)

Korábbi megoldások, előnyeik, hátrányaik


	klasszikus képfeldolgozás	hagyományos gépi tanulás	CNN-alapú objektumdetektálás	szemantikus szegmentáció	instance szegmentáció
működés	küszöbölés, éldetektálás, ...	kézi feature-ök + klasszifikátor	bounding box alapú megoldások	pixel-szintű osztályozás	objektum és maszk alapú megközelítés
előnyök	Egyszerű és gyors	alacsony számítási igény	objektumszintű felismerés	jó alak és pozíciófelismerés osztályszinten	objektumok pontos elkülönítése
hátrányok	érzékenység zajra, kontrasztra, megvilágosításra	gyenge teljesítmény komplex mintázatokon	pontatlan objektumalakok	azonos osztályú objektumok összefolynak	nagy számítási igény, adatminőségre érzékenység

Rendszerterv

- teljes feldolgozási pipeline kialakítása
- adatletöltés és validáció
- annotációk tisztítása
- előfeldolgozás
 - képek átméretezése
 - kiegyensúlyozott mintavételezés
- modellek tanítása és összehangolása

Adatbázis

- Airbus Ship Detection dataset
- 768x768 RGB műholdképek
- Run-Length Encoded mask-ok
- problémák
 - összefüggéstelen alakzatok egy maszkon belül
 - túl kicsi, zajos annotáció
- tisztítási lépések
 - kapcsolat alakzatok elemzése
 - legnagyobb alakzatok megtartása
 - átfedés vizsgálata



▲ ImagedId	▲ EncodedPixels
192556 unique values	[null] 65% 43801 1 44567 4 4... 0% Other (81721) 35%
00003e153.jpg	
0001124c7.jpg	
000155de5.jpg	264661 17 265429 33 266197 33 266965 33 267733 33 268501 33 269269 33 270037 33 270805 33 271573 33 ...
000194a2d.jpg	360486 1 361252 4 362019 5 362785 8 363552 10 364321 10 365090 9 365858 10 366627 10 367396 9 368165...

Data Explorer
31.41 GB

- ▶ test_v2
- ▶ train_v2
- sample_submission_v2.csv
- train_ship_segmentations...

Summary

- ▶ 208k files

Architektúra, tanítás, nehézségek és megoldásuk

Architektúra

- *model*: U-Net
- *kimenet*: bináris valószínűségi maszk

Tanítás

- Adam optimalizáció
- Binary Cross Entropy + Dice
- kiegyensúlyozott tanítóhalmaz
- kiértékelés: IoU, F2 Score

Hiperparaméter optimalizáció

- batch size
- képek mérete




Nehézségek és megoldásuk

- Erős osztály-egyensúlytalanság
 - speciális mintavételezés
- kis objektumok
 - IoU és F2 használata accuracy helyett
- zajos annotációk
 - adatbázis tisztítás

Eredmények és ezek kiértékelése

	U-Net	CNN	Mask R-CNN	SAM	Random Forest
eredmények	$IoU = \sim 0.45$ $F2\ score = \sim 0.65$	accuracy = 0.89	$F2\ score = 0.08$	$IoU = 0.03$	accuracy = 0.74
megfigyelések	jó alak és pozíció felismerés egyszerűbb képeken	megbízható <i>ship</i> / <i>no-ship</i> predikció	gyenge detektálás	inkonzisztens maszkok	viszonylag jó <i>ship</i> / no <i>ship</i> predikció

DEMO



Összefoglalás

- az U-Net alkalmas és hatékony megoldás a vizsgált feladatra
- az adatok ellenőrzése kulcsfontosságú
- teljesítményjavulás finomhangolással és architekturális bővítésekkel várható